

11/11/17

07:55

Fazer as listas de Machine Learning:

Questão 1 -

Modelo de regressão linear:

$D = \{(x_i, y_i) \mid i \in N\} \rightarrow N$  pontos  $(x_i, y_i)$

$\hookrightarrow x_i =$  observado, dimensão " $D$ "

$\hookrightarrow$  Então podemos definir uma matriz  $X$ , tal que:  $\{x_{ij} \in X \mid x_{ij}$  é o valor do feat.  $j$  do ponto  $i\}$

$\hookrightarrow$  onde  $1 \leq i \leq N$  e  $1 \leq j \leq D$

$\rightarrow$  Eu tenho um modelo com parâmetros " $\theta$ ".

Quais são os parâmetros que eu devo escolher?

$\hookrightarrow$  Se " $p(D|\theta)$ " é a probabilidade dos dados terem sido gerados por um determinado modelo ( $\theta$ ), seria bom escolher os parâmetros tais que:

$\hat{\theta} = \arg \max_{\theta} p(D|\theta)$ , ou seja, encontrar o  $\theta$  que maximiza a probabilidade dos dados serem gerados por esse modelo.

$\rightarrow$  Para hipótese: os valores de " $y$ " são normalmente distribuídos em torno de um valor ( $\mu_i$ ) que depende linearmente de  $x_i$ . Então:

$p(D|\theta) = \prod p(y_i | w^T x_i)$   $\rightarrow w$ : são os pesos

$\hookrightarrow$  erros são independentes (por hipótese)

$\rightarrow$  Do onde  $p(D|\theta) = \prod_{i=1}^N \frac{1}{\sigma^2 \sqrt{2\pi}} e^{-\frac{(y_i - \mu_i)^2}{2\sigma^2}}$

Aplicando log:  $\log(p(D|\theta)) = -\log(\sigma^2 N)$

\* Inicialmente temos:

$D = \{(x_i, y_i) \mid i \in N\}$   $N$  pontos " $i$ "

$\hookrightarrow$  dados observados (dimensão  $D$ )

$\hookrightarrow x_i \in X$  tal que:  $\{x_{ij} \in X\}$  matriz

Onde " $x_{ij}$ " é o valor de ponto " $i$ " do feature " $j$ ".

\* Modelo:  $\bar{y}_i = w_1 x_{i1} + w_2 x_{i2} + \dots + w_D x_{iD}$

Onde:  $\bar{y}_i = \mu_i$ , para  $N_{\mu_i}(\sigma_i, \mu_i)$  é dist. de " $y$ " para o ponto  $x_i$ .

ou seja:

$\hookrightarrow$  erro normalmente distribuído

Hip. 1:  $y_i(x_i) = \bar{y}_i(x_i) + \epsilon(x_i)$

outro aspecto importante do modelo é que os resultados (" $y_i$ ") são independentes entre si. (Hip. 2).

\* Problema: Eu tenho um modelo, um modelo tem um conjunto de parâmetros desconhecidos. Quais os valores dos parâmetros que devo escolher?

$\hookrightarrow$  Eu sei que para um conjunto de parâmetros é possível calcular a probabilidade dos dados serem gerados pelo modelo (likelihood =  $p(D|\theta)$ ). Parece ser uma boa ideia

buscar quais os parâmetros que maximizam a probabilidade, ou seja:

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}} p(D|\theta) \quad (1)$$

Pelo "Hip. 1":  $P(y_i|\theta) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(y_i - \bar{w}x_i)^2}{2\sigma^2}}$

Pelo "Hip. 2":  $P(D|\theta) = \prod_{i=1}^N P(y_i|\theta) \Rightarrow$  como:

$$\underset{\theta}{\operatorname{argmax}} p(D|\theta) = \underset{\theta}{\operatorname{argmax}} \log(p(D|\theta)) = \hat{\theta} \Rightarrow$$

$$\Rightarrow \hat{\theta} = \underset{\theta}{\operatorname{argmax}} \left[ \log\left(\prod_{i=1}^N \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(y_i - \bar{w}x_i)^2}{2\sigma^2}}\right) \right] = \Rightarrow$$

$$\Rightarrow \hat{\theta} = \underset{\theta}{\operatorname{argmax}} \left[ -\frac{N}{2}(\log(2\pi)) - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \bar{w}x_i)^2 \right]$$

Essa manipulação é interessante porque reduz a minimização de um produto a algo mais simples (minimização somatória).

Neste caso podemos definir que:

$$\max_{\theta} \log \text{likelihood} = \min_{\theta} \text{neg log likelihood (NLL)}$$

$$\text{e } \min_{\theta} \text{NLL} = \min_{\theta} \text{RSS}$$

Co é e por isso (pelo MLE, hip. 1 e hip. 2) que faz sentido buscar o modelo que minimize o RSS.

Se definirmos (por conveniência):

$$\text{NLL}(\bar{w}) = \frac{1}{2} \sum_{i=1}^N (y_i - \bar{w}x_i)^2 \Rightarrow$$

$$\text{NLL}(X) = \frac{1}{2} (\bar{y} - [X]\bar{w})^T (\bar{y} - X\bar{w})$$

FOUNDA  
VETORIAL

$$\begin{aligned} \text{NLL}(\bar{w}) &= \frac{1}{2} (\bar{y} - [X]\bar{w})^T (\bar{y} - [X]\bar{w}) = \\ &= \frac{1}{2} (\bar{y}^T \bar{y} - \bar{y}^T [X]\bar{w}) - ([X]\bar{w})^T \bar{y} + ([X]\bar{w})^T ([X]\bar{w}) \\ &= \frac{1}{2} \bar{y}^T \bar{y} - \underbrace{\frac{1}{2} (\bar{w}^T [X]^T \bar{y})}_{\text{Dimensão 1}} - \underbrace{\frac{1}{2} \bar{w}^T [X]^T \bar{y}}_{\text{Dimensão 1}} + \frac{1}{2} \bar{w}^T [X]^T [X] \bar{w} = \\ &= \frac{1}{2} \bar{y}^T \bar{y} - \bar{w}^T [X]^T \bar{y} + \frac{1}{2} \bar{w}^T [X]^T [X] \bar{w} = \text{NLL}(\bar{w}) \end{aligned}$$

$$\Rightarrow \frac{\partial \text{NLL}}{\partial \bar{w}} = \frac{\partial}{\partial \bar{w}} \left( \frac{1}{2} \bar{y}^T \bar{y} \right) - \frac{\partial}{\partial \bar{w}} \bar{w}^T [X]^T \bar{y} + \frac{1}{2} \frac{\partial \bar{w}^T [X]^T [X] \bar{w}}{\partial \bar{w}} \Rightarrow$$

$$\Rightarrow \frac{\partial \text{NLL}}{\partial \bar{w}} = -[X]^T \bar{y} + \frac{1}{2} ([X]^T [X])^T + [X]^T [X] \bar{w} \Rightarrow$$

$$\Rightarrow \frac{\partial \text{NLL}(\bar{w})}{\partial \bar{w}} = -[X]^T \bar{y} + [X]^T [X] \bar{w} \Rightarrow$$

$$\Rightarrow \frac{\partial \text{NLL}(\bar{w})}{\partial \bar{w}} = 0 \Rightarrow [X]^T [X] \bar{w} = [X]^T \bar{y} \Rightarrow$$

$$\hat{\theta} = \hat{\bar{w}} = ([X]^T [X])^{-1} [X]^T \bar{y}$$

P  
Modelo  
Linear

20/11/17

Modelo Covariante multivariado:

01:57

$f(\vec{x}) = N(\vec{x} | \theta) \rightarrow$  Normal multi-  
 variada depende  
 de  $\mu$  e  $[\sigma]$   
 no ponto  $\vec{x}$

$\rightarrow$  conjunto de  $N$  pontos " $x_i$ "

$$\Rightarrow L(\theta | X) = \prod_{i=1}^N N(\vec{x}_i | \theta) \Rightarrow$$

$$\Rightarrow \hat{\theta} = \underset{\theta}{\text{argmax}} L(\theta | X) = \underset{\theta}{\text{argmax}} \log(L(\theta | X)) \Rightarrow$$

$$\Rightarrow \log(L(\theta | X)) = \sum_{i=1}^N \log(N(\vec{x}_i | \vec{\mu}_y, [\sigma_y])) \Rightarrow$$

$$\Rightarrow \log(L(\theta | X)) = \sum_{i=1}^N \log\left(\frac{1}{\sqrt{2\pi}[\sigma_y]} e^{-\frac{1}{2}(\vec{x}_i - \vec{\mu}_y)^T [\sigma_y^{-1}] (\vec{x}_i - \vec{\mu}_y)}\right)$$

$$\Rightarrow \log(L(\theta | X)) = -\frac{N}{2} \sqrt{2\pi}[\sigma_y] - \frac{1}{2} \sum_{i=1}^N (\vec{x}_i - \vec{\mu}_y)^T [\sigma_y^{-1}] (\vec{x}_i - \vec{\mu}_y)$$

$$\Rightarrow \text{Seja } f(\theta) = -\frac{N}{2} \sqrt{2\pi}[\sigma_y] - \frac{1}{2} \sum_{i=1}^N (\vec{x}_i - \vec{\mu}_y)^T [\sigma_y^{-1}] (\vec{x}_i - \vec{\mu}_y) \Rightarrow$$

$$f'(\theta^*) = 0 \Rightarrow \theta^* = \hat{\theta} \Rightarrow$$

$$\Rightarrow \frac{\partial f}{\partial \mu} = -\frac{1}{2} \sum_{i=1}^N \frac{2(\vec{x}_i - \vec{\mu}_y)^T [\sigma_y^{-1}] (\vec{x}_i - \vec{\mu}_y)}{2 \mu_y}$$

$$\text{Seja } \alpha = (\vec{x}_i - \vec{\mu}_y) \Rightarrow d\alpha = -d\mu_y$$

$$\Rightarrow \frac{\partial f}{\partial \mu} = -\frac{1}{2} \sum_{i=1}^N \frac{2(\vec{x}_i - \vec{\mu}_y)^T [\sigma_y^{-1}] (\vec{x}_i - \vec{\mu}_y)}{2 \mu_y}$$

$$= -\frac{1}{2} \sum_{i=1}^N ([\sigma_y^{-1}] + [\sigma_y^{-1}]^T) \alpha =$$

$$= \frac{1}{2} \sum_{i=1}^N \left( ([\sigma_y^{-1}] + [\sigma_y^{-1}]^T) \cdot (\vec{x}_i - \vec{\mu}_y) \right) = 0 \Rightarrow$$

$$\Rightarrow \sum_{i=1}^N [\beta] \vec{x}_i = \sum_{i=1}^N [\beta] \vec{\mu}_y \Rightarrow$$

$$\Rightarrow [\beta] \sum_{i=1}^N \vec{x}_i = [\beta] \vec{\mu}_y N \Rightarrow$$

$$\left[ \frac{\sum_{i=1}^N \vec{x}_i}{N} = \vec{\mu}_y = \hat{\mu}_y \right]$$